

Introduction à l'intelligence artificielle

D'où vient l'IA, pourquoi elle explose maintenant, ce que recouvrent les mots IA, machine learning et deep learning, et à quoi ressemble un réseau de neurones.

ON REPART AVEC • Une frise que tu sais raconter, la différence classification / régression, et un premier réseau de neurones que tu as fait apprendre toi-même dans le Playground.

01 UNE FRISE, DE 1950 À AUJOURD'HUI 02 POURQUOI MAINTENANT
03 EST-CE QUE ÇA VA DURER ? 04 LES TROIS CERCLES 05 LA CARTE DU MACHINE LEARNING
06 CLASSIFICATION OU RÉGRESSION 07 UN RÉSEAU DE NEURONES

À LA FIN DE LA SÉANCE

Tu sauras dire pourquoi 2012 est la vraie rupture de la frise, et pas 1957 ni 2022.
Tu sauras placer un exemple dans le bon cercle, IA, machine learning ou deep learning.
Tu sauras reconnaître une classification d'une régression à la forme de la réponse.

Une frise, de 1950 à aujourd'hui

L'IA n'est pas née avec ChatGPT : l'idée a soixante-quinze ans. Fais défiler. Quand des sources sérieuses ne s'accordent pas sur un chiffre, la carte le dit.

LES FONDATIONS • 1950 – 1969

octobre 1950 • Le test de Turing : Dans la revue Mind, Alan Turing propose le « jeu de l'imitation » : une machine réussit si un juge, par écrit, ne parvient pas à la distinguer d'un humain.

été 1956 • La conférence de Dartmouth : Un atelier d'été réunit McCarthy, Minsky, Rochester et Shannon ; leur proposition de 1955 emploie pour la première fois l'expression « intelligence artificielle ».

1957 – 1958 • Le perceptron de Rosenblatt : Frank Rosenblatt décrit le perceptron, un premier neurone artificiel qui apprend à reconnaître des formes ; le New York Times y voit l'embryon d'une machine consciente.

janvier 1966 • ELIZA : Au MIT, Joseph Weizenbaum publie ELIZA, un programme qui imite un psychologue en reformulant les phrases de l'utilisateur grâce à quelques règles simples.

LES HIVERS • 1970 – 1993

1973 • Le rapport Lighthill et le premier hiver : Commandé par le Science Research Council britannique, le rapport Lighthill juge les promesses de l'IA non tenues et entraîne l'arrêt des financements dans la plupart des universités du Royaume-Uni.



1980 – 1993 · Essor puis chute des systèmes experts : XCON, en service chez DEC dès 1980, économe 25 millions de dollars par an ; en 1987 le marché des machines LISP s'effondre et un second hiver commence.

9 octobre 1986 · La rétropropagation popularisée : Rumelhart, Hinton et Williams publient dans Nature l'article qui popularise la rétropropagation, la méthode d'entraînement des réseaux de neurones à plusieurs couches encore utilisée aujourd'hui.

LA RENAISSANCE · 1994 – 2011

11 mai 1997 · Deep Blue bat Kasparov : À New York, l'ordinateur Deep Blue d'IBM bat le champion du monde d'échecs Garry Kasparov 3,5 à 2,5, un an après avoir perdu le premier match 4 à 2.

2009 · ImageNet : L'équipe de Fei-Fei Li présente ImageNet, une base de plus de 14 millions d'images annotées à la main, qui sert de référence aux concours de reconnaissance visuelle dès 2010.

LE DEEP LEARNING · 2012 – 2016

30 septembre 2012 · AlexNet : Le réseau de neurones AlexNet, entraîné sur deux cartes graphiques, remporte le concours ImageNet avec 15,3 % d'erreur, plus de 10 points devant le deuxième.

16 janvier 2013 · word2vec : Chez Google, Tomáš Mikolov et ses collègues publient word2vec, qui représente chaque mot par une liste de nombres telle que « frère » – « homme » + « femme » donne « sœur ».

9 – 15 mars 2016 · AlphaGo bat Lee Sedol : À Séoul, AlphaGo de DeepMind bat le champion de go Lee Sedol 4 à 1, un exploit que la plupart des experts n'attendaient pas avant plusieurs années.

LES TRANSFORMERS · 2017 – 2022

12 juin 2017 · « Attention is all you need » : Huit chercheurs, alors chez Google (dont un étudiant de Toronto en stage), décrivent le Transformer, une architecture fondée uniquement sur le mécanisme d'attention, qui devient la base de presque tous les grands modèles de langage.

11 octobre 2018 · BERT : Google publie BERT, un modèle qui lit un texte dans les deux sens à la fois et devient la référence pour de nombreuses tâches de compréhension du langage.

14 février 2019 · GPT-2 : OpenAI annonce GPT-2, 1,5 milliard de paramètres, mais refuse d'abord de publier le modèle complet par crainte d'usages malveillants ; il est diffusé le 5 novembre 2019.

28 mai 2020 · GPT-3 : OpenAI présente GPT-3, 175 milliards de paramètres, dix fois plus que tout modèle précédent, capable d'accomplir une tâche à partir de quelques exemples donnés dans la consigne.

novembre 2020 · AlphaFold 2 : AlphaFold 2 de DeepMind remporte le concours CASP14 en prédisant la forme des protéines ; l'article paraît dans Nature le 15 juillet 2021 avec le code en accès libre.

avril – août 2022 · L'année des images générées : DALL·E 2 (6 avril), Midjourney (bêta ouverte le 12 juillet) puis Stable Diffusion (22 août, poids publics) permettent à chacun de créer une image à partir d'une phrase.

30 novembre 2022 · ChatGPT : OpenAI ouvre ChatGPT, fondé sur GPT-3.5 : un million d'utilisateurs en cinq jours, cent millions en deux mois, et l'IA générative entre dans le grand public.

LE BOOM · 2023 – AUJOURD'HUI

24 février 2023 · LLaMA et les modèles ouverts : Meta réserve LLaMA aux chercheurs sous licence non commerciale ; les poids fuient le 3 mars, puis Llama 2 (18 juillet) autorise l'usage commercial et lance la vague des modèles ouverts.

14 mars 2023 · GPT-4 (et Claude) : OpenAI lance GPT-4, qui accepte aussi des images et se classe les 10 % meilleurs à un examen du barreau simulé ; le même jour, Anthropic présente Claude.



mars – novembre 2023 · L'année des alertes : Une lettre ouverte demande une pause de six mois (mars), Geoffrey Hinton quitte Google pour alerter librement (1er mai), et 28 pays signent la déclaration de Bletchley (1er-2 novembre).

6 décembre 2023 · Gemini : Google annonce Gemini 1.0, conçu d'emblée pour traiter texte, code, audio, image et vidéo ; sa version Ultra est présentée comme la première à dépasser les experts humains sur le test MMLU.

13 mars 2024 · L'AI Act européen : Le Parlement européen adopte l'AI Act par 523 voix contre 46 ; en vigueur le 1er août 2024, il s'applique par étapes : interdictions en février 2025, modèles généraux en août 2025.

12 septembre 2024 · o1 et les modèles de raisonnement : OpenAI lance o1-preview, un modèle qui « réfléchit » avant de répondre : il résout 83 % des problèmes d'un examen qualificatif d'olympiade de mathématiques, contre 13 % pour GPT-4o.

8 et 9 octobre 2024 · Deux prix Nobel pour l'IA : John Hopfield et Geoffrey Hinton reçoivent le Nobel de physique pour les réseaux de neurones ; le lendemain, David Baker, Demis Hassabis et John Jumper obtiennent celui de chimie, notamment pour AlphaFold.

20 – 27 janvier 2025 · DeepSeek R1 secoue les marchés : La start-up chinoise DeepSeek publie R1, un modèle de raisonnement ouvert et peu coûteux ; le 27 janvier, Nvidia perd 589 milliards de dollars en Bourse, un record historique.

janvier – mars 2025 · L'année des agents : OpenAI lance Operator (23 janvier), un agent qui navigue sur le web à la place de l'utilisateur ; Manus (6 mars) et d'autres popularisent des agents qui planifient et exécutent des tâches.

janvier – avril 2025 · Centres de données et énergie : Stargate promet jusqu'à 500 milliards de dollars de centres de données aux États-Unis (21 janvier) ; l'AIE prévoit que leur consommation électrique mondiale passe de 415 TWh en 2024 à 945 TWh en 2030.

7 août 2025 · GPT-5 : OpenAI déploie GPT-5 à tous les utilisateurs de ChatGPT, alors 700 millions par semaine ; un « routeur » choisit entre réponse rapide et réflexion longue, et l'accueil est mitigé.

29 octobre 2025 · Nvidia vaut 5 000 milliards : Nvidia devient la première entreprise valorisée 5 000 milliards de dollars, trois mois après le cap des 4 000 ; ChatGPT compte alors 800 millions d'utilisateurs hebdomadaires.

9 juin 2026 · Claude Fable 5 et Mythos 5 : Anthropic ouvre au public Claude Fable 5, version bridée de son modèle Mythos : les requêtes sensibles (cybersécurité, biologie, chimie) sont détournées vers un modèle moins puissant.

27 juillet 2026 · L'AI Act ajusté : l'omnibus numérique : Le règlement « omnibus » entre en vigueur et repousse les obligations des systèmes à haut risque au 2 décembre 2027 ; les règles de transparence s'appliquent bien le 2 août 2026.

28 juillet 2026 · Les employés de l'IA demandent un frein : Plus de 1 100 salariés d'OpenAI, Anthropic, Google et Meta, dont Dario Amodei, demandent aux États-Unis des outils pour pouvoir ralentir le développement automatisé de l'IA si nécessaire.

3 septembre 2026 · GPT-6 Astra : OpenAI dévoile GPT-6 Astra, entraîné sur plus de 100 000 GPU au site Stargate du Texas ; son président Greg Brockman parle d'entrée dans « l'ère de l'AGI », ce que des experts contestent.



01

Hivers

2

Deux fois, les promesses n'ont pas été tenues et les financements ont disparu. Ça peut arriver de nouveau.

pour aller plus loin

Premier hiver, vers 1974–1980 : le rapport Lighthill (1973) juge les promesses non tenues, les financements britanniques puis américains se tarissent.

Second hiver, vers 1987–1993 : le marché des machines Lisp s'effondre en 1987, le projet japonais de cinquième génération s'achève en 1992 sans avoir tenu ses objectifs.

Lighthill report (Wikipedia) ↗ · AI winter (Wikipedia) ↗ · vérifié le 2026-09-25

02

Accélération

1

Une seule architecture depuis 2017, le transformer, derrière les modèles de texte, d'image, de son et de code.

pour aller plus loin

Un transformer lit tous les mots d'une phrase en même temps et apprend lesquels regarder pour comprendre chacun (le mécanisme d'attention), au lieu de les lire un par un.

Décrit en juin 2017 par huit chercheurs alors chez Google, dans « Attention Is All You Need ».

Vaswani et al., arXiv:1706.03762 (2017) ↗ · vérifié le 2026-09-25


Pourquoi maintenant

Les idées sont anciennes, les moyens sont récents : le neurone artificiel date de 1957, et il a fallu attendre 2012 pour qu'un ordinateur soit assez puissant, et les données assez nombreuses, pour qu'il serve vraiment. Trois causes à ce rattrapage, aucune ne suffit seule ; « détails et sources » dit d'où vient chaque chiffre.



CAUSE 1

La puissance de calcul



Multiplié par 4 à 5 chaque année : de 10^{17} à plus de 10^{26} opérations par entraînement en treize ans (Epoch AI).

détails et sources


Un réseau de neurones passe son temps à faire la même multiplication sur des millions de nombres à la fois. Une carte graphique, conçue pour calculer les pixels des jeux vidéo, est faite exactement pour ça.

Les points de la courbe (Epoch AI, base des modèles notables, consultée le 25/09/2026) : AlexNet 2012, $4,7 \times 10^{17}$ FLOP ; Transformer 2017, $7,4 \times 10^{18}$; BERT-Large 2018, $2,9 \times 10^{20}$; GPT-3 2020, $3,1 \times 10^{23}$; PaLM 2022, $2,5 \times 10^{24}$; GPT-4 2023, $2,1 \times 10^{25}$; Grok 3 2025, $3,5 \times 10^{26}$.

Un processeur grand public récent, l'Intel Core Ultra 9 285K (fin 2024), a 24 cœurs. Une carte graphique GeForce RTX 5090 (2025) en a 21 760. Les deux sortes de cœurs ne se valent pas un pour un : ce qui compte, c'est le nombre d'opérations menées en même temps.

CAUSE 2

Le déluge de données



Un zettaoctet vaut mille milliards de gigaoctets ; estimations IDC successives, 2025 en pointillé car prévue en 2021.


détails et sources

Un zettaoctet, c'est mille milliards de gigaoctets : de quoi remplir 8 milliards de smartphones de 128 Go. Textes, photos, vidéos, clics : c'est la matière première. Sans elle, les réseaux de neurones actuels n'auraient rien à apprendre, et c'est pour ça qu'ils ne pouvaient pas exister il y a vingt ans.

Les points de la courbe, d'après les études IDC successives : 1,8 zettaoctet en 2011 (Digital Universe 2011), 2,8 en 2012 (Digital Universe, déc. 2012), 4,4 en 2013 (Digital Universe 2014), 33 en 2018 (Data Age 2025, nov. 2018), 64,2 en 2020 et 181 prévus pour

CAUSE 3

Un coût divisé par mille



À niveau égal, le prix est divisé par dix chaque année : meilleurs algorithmes, meilleures puces (a16z, OpenAI).

détails et sources

En juin 2017, un article de huit chercheurs, alors chez Google, propose le transformer : un réseau qui lit tous les mots d'une phrase en même temps au lieu d'un par un, donc exactement ce qu'un GPU sait accélérer. Presque tous les grands modèles actuels en descendent. Et les idées continuent de s'améliorer : à puissance égale, on fait deux fois mieux tous les huit mois environ.

Les points de la courbe : GPT-3 davinci, 60 \$ le million de tokens en novembre 2021 (a16z) ; GPT-3.5 Turbo, 2 \$ le 1er mars 2023 (OpenAI : « 10 fois moins cher ») ; 0,50 \$ en entrée le 25 janvier 2024 (OpenAI) ; GPT-4o mini, 0,15 \$ en entrée le 18 juillet 2024 (OpenAI) ; Llama 3.2 3B, 0,06 \$ fin 2024 (a16z). Même niveau de test MMLU, environ 42, d'un bout à l'autre.

Vaswani et al., « Attention Is All You Need », soumis le 12 juin 2017 : huit auteurs, tous chez Google Brain ou Google Research à l'époque, l'u

AlexNet (2012), le réseau qui a lancé le deep learning moderne, a été entraîné pendant cinq à six jours sur deux cartes de jeu vidéo GTX 580.

D'après Epoch AI, le calcul consacré à l'entraînement des plus gros modèles est multiplié par 4 à 5 chaque année depuis 2010.

Le GPU que Colab prête en général gratuitement, le NVIDIA T4 (2018) : 2 560 cœurs et 16 Go de mémoire. Google ne garantit pas le modèle attribué.

Krizhevsky, Sutskever, Hinton, « ImageNet Classification with Deep Convolutional Neural Networks », NeurIPS 2012 ↗ · vérifié le 2026-09-25

aussi : Intel Core Ultra 9 285K, fiche technique Intel · GeForce RTX 5090, fiche NVIDIA · NVIDIA T4, fiche produit · Epoch AI, « Training Compute of Frontier AI Models Grows by 4-5x per Year » (mai 2024) · NVIDIA, « What's the Difference Between a CPU and a GPU? » · Google Colab, FAQ (les GPU disponibles varient) · Epoch AI, base « Notable AI models » (CSV) · Epoch AI, « Over 30 AI models have been trained at the scale of GPT-4 » (2025)

2025 (Global DataSphere, mars 2021). Les méthodes ont changé d'une édition à l'autre : c'est un ordre de grandeur, pas une série continue.

ImageNet, la base d'images qui a permis AlexNet : 14 millions d'images annotées à la main, dont 1,2 million dans 1 000 catégories pour le concours de 2012.

Llama 3 (Meta, 2024) a été entraîné sur plus de 15 000 milliards de mots-morceaux (tokens), sept fois plus que la version précédente.

IDC, « Global DataSphere Forecast 2021–2025 », mars 2021, cité par Redmond Channel Partner (le communiqué IDC n'est plus accessible) ↗ · vérifié le 2026-09-25

aussi : IDC, « The Digitization of the World » (nov. 2018) : la définition du zettaoctet · Data Center Knowledge, « Digital Universe to Add 1.8 Zettabytes in 2011 » · ImageNet, page « About » · Meta, « Introducing Meta Llama 3 » (avril 2024) · IDC, « The Digital Universe in 2020 » (déc. 2012) : 2,8 zettaoctets en 2012 · IDC/EMC, Digital Universe 2014 : 4,4 zettaoctets en 2013 (cité par SecurityWeek)

d'eux étudiant à l'univers. de Toronto en stage.

Ho et al. (Epoch AI, mars 2024) : le calcul requis pour un niveau donné « a été divisé par deux environ tous les 8 mois » entre 2012 et 2023, avec une large incertitude (5 à 14 mois). Le tableau de bord Epoch de février 2026 donne 7,6 mois.

Pour comparaison, le matériel progresse moins vite : la puissance des puces d'IA double tous les 2,3 ans environ (Epoch AI).

Vaswani et al., « Attention Is All You Need », arXiv:1706.03762, 12 juin 2017 ↗ · vérifié le 2026-09-25 aussi : Ho et al., « Algorithmic progress in language models », arXiv:2403.05812, mars 2024 · Epoch AI, Trends dashboard (févr. 2026) · University of Toronto, « U of T undergrad co-authors important machine learning study at Google » · a16z, « LLMflation: LLM inference cost is going down fast » (12 nov. 2024) · OpenAI, « Introducing ChatGPT and Whisper APIs » (1er mars 2023) · OpenAI, « New embedding models and API updates » (25 janv. 2024) · OpenAI, « GPT-4o mini: advancing cost-efficient intelligence » (18 juil. 2024)




Processeur (CPU)

quelques cœurs, rapides, bons à tout



une case après l'autre


la même multiplication de matrices, 16 cases à calculer



1, puis 2, puis 3... puis 16

Carte graphique (GPU)

des milliers de cœurs, lents, tous identiques



toutes les cases en même temps

la même multiplication de matrices, 16 cases à calculer



16 d'un coup

Un réseau de neurones ne fait presque que des multiplications de matrices, toutes identiques : le GPU les fait toutes en même temps.

- POUR L'ÉLÈVE CURIEUX : POURQUOI UNE CARTE DE JEU VIDÉO

Un réseau de neurones ne fait presque qu'une seule chose : **multiplier des tableaux de nombres**. Chaque neurone additionne ses entrées pondérées par des poids ; avec des milliers de neurones par couche, ça devient une multiplication de matrices, répétée pour chaque couche, pour chaque exemple, à chaque tour d'apprentissage. Des milliards d'opérations, toutes **identiques** et **indépendantes** les unes des autres.

Ton processeur (le CPU) est fait pour l'inverse : quelques cœurs très rapides et très malins, capables d'enchaîner des tâches différentes, de prendre des décisions, de sauter d'un programme à l'autre. C'est parfait pour faire tourner un navigateur, un jeu et une messagerie en même temps. C'est un chef étoilé : il fait tout, très bien, un plat à la fois.

Une carte graphique (le GPU) a été inventée pour les jeux vidéo, où il faut calculer la couleur de millions de pixels, tous avec la même formule, soixante fois par seconde. Elle contient donc des **milliers de petits cœurs**, lents et bêtes pris un par un, mais qui font tous la même opération en même temps. C'est une cantine : mille personnes, une seule recette, tout le monde servi d'un coup.

Or « la même opération sur des millions de nombres », c'est exactement ce que demande un réseau de neurones. En 2012, trois chercheurs de Toronto ont entraîné leur réseau de reconnaissance d'images, AlexNet, pendant cinq à six jours sur deux cartes de jeu vidéo au lieu de processeurs classiques : c'est le déclic du deep learning moderne, et c'est pour ça que l'entreprise qui fabriquait ces cartes, NVIDIA, est devenue l'une des plus valorisées au monde. Dans Colab, le GPU que tu utiliseras aux séances 9 à 12 (en général un T4, une carte de 2018) vient de cette histoire.



Est-ce que ça va durer ?

La carte « Hivers » de la frise pose la question, et le marché a misé des centaines de milliards sur la réponse : quatre choses doivent tenir pour que ce pari soit gagné.

01

Capacité

Est-ce que les machines vont continuer à progresser ?

- ? ON NE SAIT PAS

pour aller plus
loin

La durée d'une tâche qu'une IA mène seule, sans aide, double environ tous les 7 mois depuis 2019 (METR, mars 2025).

Une courbe qui double ne double jamais indéfiniment ; la vraie question est ce qui arrive au temps de doublement.

METR, « Measuring AI Ability to Complete Long Tasks » (mars 2025) ↗ · Kwa et al., arXiv:2503.14499 ↗ · vérifié le 2026-09-25

02

Demande

Est-ce que les gens vont s'en servir ?

☒ OUI, DÉJÀ

```
pour aller plus
loin
```

Quand une ressource devient bon marché, on en consomme plus, pas moins : c'est le paradoxe de Jevons, observé sur le charbon en 1865.

Des machines à vapeur plus économes n'ont pas fait baisser la consommation de charbon britannique : elle a triplé d'ici 1900.

Jevons, « The Coal Question » (1865), Yale Energy History ↗ · Jevons paradox (Wikipedia) ↗ · vérifié le 2026-09-25

03

Ressources

Est-ce que
l'électricité et les
usines suivent ?

- ? C'EST LE FREIN

```
pour aller plus
*****
loin
```

Les data centers du monde ont consommé environ 415 TWh d'électricité en 2024 (IEA) ; l'Allemagne entière en a produit 489 TWh la même année : à peu près autant.

Un modèle se déploie en semaines, une usine de puces se construit en années : l'usine TSMC de l'Arizona annoncée en mai 2020, n'a produit en volume qu'à la fin 2024.

IEA, « Energy and AI »
(avril 2025) ↗ ·
Fraunhofer ISE,
production électrique
allemande 2024 ↗ ·
TSMC Arizona
(Wikipedia) ↗ · vérifié
le 2026-09-25

04

Capture

Qui va gagner
l'argent ?

- ? UNCERTAIN

pour aller plus
loin


Le moteur électrique arrive dans les usines dans les années 1880 ; les usines américaines ne deviennent vraiment plus productives que dans les années 1920.

Le gain ne vient pas de l'outil, il vient de la réorganisation autour de l'outil : il a fallu reconstruire les ateliers autour de petits moteurs au lieu d'un arbre central.

Paul David, « The
Dynamo and the
Computer », *American
Economic Review*
80(2), 1990 ↗ · vérifié
le 2026-09-25

Les trois cercles

Trois mots que tout le monde mélange.




Chaque cercle est contenu dans le précédent : tout deep learning est du machine learning, tout machine learning est de l'IA, mais pas l'inverse.

La carte du machine learning

Quand quelqu'un dit « on va mettre du machine learning », il pense à l'une de ces cinq cases.





Les deux cases grisées sont celles du cours : c'est là que vivent Titanic, la météo et le prix des appartements.

- L'ANCÊTRE : LA RÉGRESSION LINÉAIRE, 1805

Le machine learning n'est pas de la magie : ce sont des mathématiques anciennes devenues calculables. Sa plus vieille méthode, la régression linéaire, consiste à faire passer la meilleure droite possible dans un nuage de points. Legendre l'a publiée en 1805 pour prédire la trajectoire des comètes, avec la méthode des moindres carrés, et Gauss a revendiqué l'avoir utilisée avant lui. Le mot « régression » vient de Francis Galton, en 1886, qui étudiait la taille des enfants par rapport à celle de leurs parents.

Deux siècles plus tard, c'est toujours le premier modèle qu'on entraîne (tu le feras à la séance 6), et un réseau de neurones n'est, au fond, qu'un empilement de régressions avec une petite courbure entre chaque couche. Ce qui a changé, ce n'est pas l'idée : c'est qu'on peut désormais la faire tourner sur des milliards de nombres.

Classification ou régression

C'est la distinction qu'on te demandera à chaque projet. Le réflexe : ne regarde pas le sujet de la question, regarde **la forme de la réponse**.

CLASSIFICATION OU RÉGRESSION ? • SUR PAPIER

Pour chaque question, dis si elle demande une catégorie (classification) ou un nombre (régression).

Classification : la réponse est une catégorie

Régression : la réponse est un nombre

1. Quelle température fera-t-il demain ?



2. Ce mail est-il un spam ?
3. Combien de vues fera cette vidéo ?
4. Cette photo montre-t-elle un chat ?
5. À quel prix se vendra cet appartement ?
6. Ce passager du Titanic a-t-il survécu ?
7. Quel genre musical est ce morceau ?
8. Dans combien de minutes arrivera le bus ?


Les réponses sont dans le corrigé, en fin de leçon.

- POURQUOI ÇA COMPTE : ON NE LES MESURE PAS PAREIL

Les deux familles ne se mesurent pas de la même façon. Une classification se juge en pourcentage de bonnes cases ; une régression se juge à la distance entre la prédiction et la vraie valeur. Se tromper de famille, c'est mesurer son modèle avec la mauvaise règle.

Un réseau de neurones

Reprenons la pomme et le melon du notebook.



Apprendre = régler tous les poids pour que la sortie colle aux exemples.
Avec des millions de poids et des dizaines de couches, c'est du deep learning.



À toi : le Playground

Ouvre le TensorFlow Playground (il faut le réseau). Choisis le jeu de données en spirale, garde une couche cachée à deux neurones, lance : le réseau n'y arrive pas. Ajoute des couches et des neurones avec les boutons +, relance, et regarde la frontière épouser la spirale. C'est ça, *deep* : la profondeur apprend des formes compliquées.

Mini-quiz

MINI-QUIZ · SUR PAPIER

Une seule bonne réponse par question.

1. Sur la frise, pourquoi 2012 est-elle la vraie rupture, plutôt que 1957 ou 2022 ?
 - A. C'est l'année où l'idée du neurone artificiel est trouvée
 - B. Un réseau de neurones gagne enfin, grâce aux cartes graphiques et à une grande base d'images
 - C. C'est la sortie de ChatGPT
 - D. Les chercheurs inventent le transformer
2. Pourquoi une carte graphique entraîne-t-elle un réseau de neurones plus vite qu'un processeur ?
 - A. Ses cœurs sont plus rapides un par un
 - B. Elle a plus de mémoire
 - C. Elle a des milliers de petits cœurs qui font la même opération en même temps
 - D. Elle est branchée directement à Internet
3. Un GPS qui calcule l'itinéraire le plus rapide, où le places-tu dans les trois cercles ?
 - A. Dans le deep learning : il utilise un réseau de neurones
 - B. Dans le machine learning : il apprend des trajets
 - C. Dans l'intelligence artificielle seulement : des règles écrites à la main, rien d'appris
 - D. Nulle part : ce n'est pas de l'IA
4. Dans un réseau de neurones, qu'est-ce qui change pendant l'apprentissage ?
 - A. Le nombre de couches
 - B. Les poids des liens entre neurones, un peu à chaque erreur
 - C. Les données d'entrée
 - D. La question posée au réseau

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Les idées datent de 1957, la rupture de 2012, l'accélération de 2017, avec deux hivers entre-temps.



2. Trois causes au boom, aucune ne suffit seule, du calcul, des données, de meilleurs algorithmes.
3. Un GPU gagne parce qu'il fait des milliers de fois la même multiplication en même temps.
4. Tout deep learning est du machine learning, tout machine learning est de l'IA, pas l'inverse.
5. Apprendre, pour un réseau de neurones, c'est régler ses poids un peu à chaque erreur.



Corrigé

Classification ou régression ?

1. **Régression** · La réponse est un nombre sur une échelle continue : 14,5 °C, 22 °C... Entre deux valeurs, il y en a toujours une autre.
2. **Classification** · La réponse est l'une de deux cases : spam ou pas spam. Pas de « à moitié spam ».
3. **Régression** · On prédit une quantité : 300, 12 000, 2 millions. La bonne réponse peut être « pas loin ».
4. **Classification** · Oui ou non : deux catégories. Avec chat, chien, lapin, on aurait trois catégories, c'est toujours une classification.
5. **Régression** · Un montant en euros : un nombre, sur une échelle continue.
6. **Classification** · Survécu ou non : c'est exactement la question du projet Kaggle des séances 7 et 8.
7. **Classification** · Rock, jazz, rap... : on choisit une étiquette dans une liste, même si la liste est longue.
8. **Régression** · Une durée : 3 minutes, 7 minutes et demie. Un nombre, pas une case.

Mini-quiz

1. **B. Un réseau de neurones gagne enfin, grâce aux cartes graphiques et à une grande base d'images** · L'idée date de 1957, ChatGPT de 2022 et le transformer de 2017. En 2012, AlexNet gagne le concours ImageNet, entraîné sur deux cartes de jeu vidéo : les moyens rattrapent enfin l'idée.
2. **C. Elle a des milliers de petits cœurs qui font la même opération en même temps** · Ses cœurs sont plus lents et plus bêtes pris un par un. Mais un réseau de neurones fait des millions de fois la même multiplication, et ça, des milliers de cœurs identiques le font d'un coup.
3. **C. Dans l'intelligence artificielle seulement : des règles écrites à la main, rien d'appris** · Il imite une capacité humaine, trouver un chemin, donc c'est de l'IA. Mais l'algorithme est écrit à la main, sans exemples : ni machine learning, ni deep learning. Le grand cercle, pas les petits.
4. **B. Les poids des liens entre neurones, un peu à chaque erreur** · L'architecture et les données sont fixées avant. Apprendre, c'est régler les poids : à chaque exemple raté, on les décale un peu, des millions de fois, jusqu'à ce que la sortie colle aux exemples.

