

Analyser et raconter

L'analyse exploratoire comme une enquête : repérer une tendance, une anomalie, une corrélation, déjouer trois pièges, puis construire un mini-dashboard et le présenter à un client en deux minutes.

ON REPART AVEC • Un mini-dashboard présenté à voix haute en 2 minutes, comme devant un client.




- 01 UNE ENQUÊTE, TROIS INDICES
- 02 TROIS PIÈGES
- 03 UN TABLEAU DE BORD
- 04 RACONTER EN DEUX MINUTES
- 05 ENTRE DEUX SÉANCES

À LA FIN DE LA SÉANCE

- Tu sauras repérer une tendance, une anomalie et une corrélation, avec le graphique qui montre chacune.
- Tu sauras reconnaître trois pièges, une corrélation lue comme une cause, un graphique trompeur, un échantillon biaisé.
- Tu sauras assembler un tableau de bord Plotly et le présenter en trois temps, constat, preuve, recommandation.

Une enquête, trois indices

Un tableau de 800 lignes ne dit rien à personne. L'analyse exploratoire, c'est faire connaissance avec les données avant de conclure : on regarde tout, on note ce qui est bizarre.



- LA RÈGLE DES 1,5 ÉCARTS

On mesure l'écart entre le premier quart des valeurs et le troisième : pour les HP, de 50 à 80, soit 30. Tout ce qui dépasse le troisième quart de plus d'une fois et demie cet écart est suspect : au-delà de $80 + 45 = 125$. Même chose par le bas : Shedinja, avec 1 HP, sort aussi de la boîte.


Une anomalie n'est pas forcément une erreur. Blissey a vraiment 255 HP : c'est souvent la chose la plus intéressante à raconter.

Trois pièges

Une corrélation, un graphique et un échantillon peuvent tous raconter une histoire fausse avec des chiffres justes.

CAUSALITÉ · LA VARIABLE CACHÉE

Les glaces causent-elles les noyades ?




120 journées simulées par le notebook

Une corrélation dit « ça bouge ensemble », jamais « l'un cause l'autre ».

GRAPHIQUE TROMPEUR · L'AXE TRONQUÉ

Les mêmes six mois d'abonnés




de 1020 à 1071 abonnés, de janvier à juin

Pour des barres, l'axe vertical part de zéro ; sinon le dessin invente l'écart.

BIAIS · L'ÉCHANTILLON MAL CHOISI

Combien de gens jouent aux jeux vidéo ?



1000 personnes simulées par le notebook

Un chiffre précis, calculé sur les mauvaises personnes, reste faux.

QUEL PIÈGE ? · SUR PAPIER

Pour chaque affirmation, nomme le piège qui s'y cache.

Causalité : on lit une cause dans une corrélation, alors qu'une variable cachée peut expliquer les deux

Graphique trompeur : le dessin grossit ou écrase un écart : axe qui ne part pas de zéro, perspective, échelle trafiquée

Biais : les données viennent d'un groupe qui ne ressemble pas à celui dont on parle


1. Les élèves qui ont un ordinateur portable ont de meilleures notes : donnons un portable à tout le monde !
2. Notre appli est passée de 4,1 à 4,3 étoiles : sur le graphique, la barre est deux fois plus haute.
3. 95 % des avis sur notre jeu sont positifs ; seuls les joueurs qui l'ont fini ont été invités à noter.
4. Les enfants qui dorment avec une veilleuse deviennent plus souvent myopes : éteignons les veilleuses.
5. Pour savoir si les élèves aiment la cantine, on interroge ceux qui y mangent, un jour de frites.

6. Sur un camembert en 3D penché, la part du premier plan paraît plus grosse qu'une part égale au fond.

Les réponses sont dans le corrigé, en fin de leçon.

Un tableau de bord

Plotly rend chaque graphique interactif : on survole un point, on zoome, on masque une catégorie en cliquant sur la légende. Assemblés, trois graphiques font un tableau de bord.



Un tableau de bord rassemble trois ou quatre graphiques qui répondent aux questions d'un client.

```
fig = px.scatter(tips, x="total_bill", y="tip", color="day", size="size")
fig.show()
```

- ET STREAMLIT ?

Streamlit transforme un script Python en page web avec des menus et des boutons, sans écrire de HTML. Il ne tourne pas directement dans Colab, car il lui faut un serveur web : sur ton ordinateur, on l'installe avec `pip install streamlit`, on écrit `app.py`, puis on lance `streamlit run app.py`. À chaque clic, Streamlit relance le script et met la page à jour. Le notebook en montre un exemple à lire.

Raconter en deux minutes

Ton client n'a pas le temps : trois graphiques, deux minutes, trois temps.

TEMPS	CE QUE TU DIS	SUR TIPS
Constat, 20 s	Ce que tu as trouvé, en une phrase avec un chiffre	Le dimanche soir, le pourboire moyen atteint 3,26 \$, près de 9 % au-dessus de la moyenne.
Preuve, 60 s	Le graphique qui le montre, et comment le lire	Les barres du pourboire moyen par jour et par moment.
Recommandation, 40 s	Ce que le client peut faire demain	Mettre les meilleurs serveurs le dimanche soir.

À toi : ton dashboard et ton pitch

Choisis ton client : le patron du restaurant avec Tips, le créateur d'un jeu avec les Pokémon, ou quelqu'un d'autre avec ton dataset de la séance 2. Tu as 20 minutes.

Trois questions précises qui l'intéressent, et pour chacune un graphique Plotly dont le titre donne la réponse.

Un tableau de bord qui les assemble, puis la vérification des trois pièges : axe à zéro, cause ou corrélation, échantillon.

Ton pitch en trois temps, prêt à être dit à voix haute.

Entre deux séances

Le carnet `05_exercices.ipynb` : 12 exercices, de ★ à ★★★★★, avec vérification automatique, indices et solutions repliées. Il ajoute un troisième jeu de données, le catalogue Netflix, et finit par un pitch pour son responsable.

Mini-quiz

MINI-QUIZ • SUR PAPIER

Une seule bonne réponse par question.

- La corrélation entre la défense et la vitesse des Pokémon vaut 0,02. Qu'est-ce que ça veut dire ?
 - Les Pokémon rapides sont fragiles
 - La vitesse ne dit presque rien de la défense
 - La défense fait baisser la vitesse
 - Il y a une erreur dans les données

2. Blissey a 255 points de vie, bien au-delà de la limite de 125 de la boîte à moustaches. Que fais-tu de cette ligne ?
- A. Je la supprime, c'est une erreur
 - B. Je la remplace par la médiane
 - C. Je la regarde de près : c'est peut-être la chose à raconter
 - D. Je la cache dans le graphique
3. Quel titre donner au nuage « pourboire selon l'addition » dans ton tableau de bord ?
- A. Pourboire vs addition
 - B. Graphique 1
 - C. Le pourboire suit l'addition
 - D. Données Tips, colonnes total_bill et tip
4. Dans ton pitch, « mettre les meilleurs serveurs le dimanche soir », c'est quel temps ?
- A. Le constat
 - B. La preuve
 - C. La recommandation
 - D. La question

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Une analyse commence par des questions précises, auxquelles les colonnes du tableau peuvent répondre.
2. Tendence, nuage de points et droite ; anomalie, boîte à moustaches ; corrélation, corr et heatmap.
3. Une corrélation dit que deux choses bougent ensemble, jamais que l'une cause l'autre.
4. Un axe tronqué invente un écart, un échantillon biaisé donne un chiffre précis et faux.
5. Un tableau de bord répond aux questions d'un client ; le pitch dit le constat, la preuve, la recommandation.

Corrigé

Quel piège ?

1. **Causalité** · Portable et bonnes notes vont ensemble, mais un troisième facteur peut produire les deux : le revenu du foyer, un endroit calme pour travailler. Distribuer des portables ne changerait pas ce facteur.
2. **Graphique trompeur** · De 4,1 à 4,3, la note gagne moins de 5 %. Une barre qui double veut dire que l'axe démarre juste sous 4 : c'est le dessin qui fabrique l'écart.
3. **Biais** · Ceux qui ont abandonné, sans doute les moins contents, n'ont jamais eu la parole. Le chiffre est exact pour ce groupe-là, faux pour l'ensemble des joueurs.
4. **Causalité** · Une explication possible, cachée : des parents myopes laissent plus volontiers une lumière, et transmettent aussi leur myopie. Veilleuse et myopie peuvent venir de la même cause.
5. **Biais** · Ceux qui fuient la cantine ne sont pas là pour répondre, et le jour choisi flatte le menu. On apprend l'avis des habitués un bon jour, pas celui des élèves.
6. **Graphique trompeur** · Les deux parts valent autant ; la perspective agrandit ce qui est devant. Les données sont justes, c'est le dessin qui ment.

Mini-quiz

1. **B. La vitesse ne dit presque rien de la défense** · Une corrélation proche de 0 veut dire qu'aucune direction ne se dégage : on trouve de tout, des lents solides, des rapides solides, des lents fragiles. Pour lire « les rapides sont fragiles », il faudrait une corrélation nettement négative.
2. **C. Je la regarde de près : c'est peut-être la chose à raconter** · La règle des 1,5 écarts signale un suspect, pas un coupable. Blissey a vraiment 255 HP dans le jeu : une anomalie vraie est souvent le fait le plus intéressant du tableau.
3. **C. Le pourboire suit l'addition** · Un titre de tableau de bord donne la réponse, pas le nom des colonnes : le client lit la conclusion avant même de regarder les points. Les autres titres l'obligent à tout décoder lui-même.
4. **C. La recommandation** · Le constat dit ce que tu as trouvé, avec un chiffre ; la preuve montre le graphique qui l'établit ; la recommandation dit au client quoi faire demain. Une action à mener, c'est toujours la recommandation.