

Premier modèle

L'apprentissage supervisé sur 333 manchots : X et y, cacher une partie des données, lire un arbre de décision, reconnaître un modèle qui a appris par cœur, puis la même recette sur les Pokémon légendaires.

ON REPART AVEC · Un premier modèle entraîné et évalué, avec une phrase pour expliquer ce qu'il a compris.

01 APPRENDRE AVEC LA RÉPONSE 02 CACHER UNE PARTIE DES DONNÉES 03 LIRE UN ARBRE
04 APPRIS PAR CŒUR 05 ENTRE DEUX SÉANCES

À LA FIN DE LA SÉANCE

Tu sauras dire ce que sont X et y, et ce que font fit et predict.

Tu sauras couper train et test, mesurer l'exactitude et la comparer au modèle bête.

Tu sauras lire un arbre de décision et reconnaître un modèle qui a appris par cœur.

Apprendre avec la réponse

Trois espèces de manchots vivent en Antarctique, et des scientifiques en ont mesuré 344. À partir des mesures seules, une machine peut-elle deviner l'espèce ?

1. des exemples avec la réponse

trois des 333 manchots mesurés

bec	épaisseur	nageoire	poids	espèce
39,1	18,7	181	3750	Adélie
46,5	17,9	192	3500	Chinstrap
50	15,3	220	5550	Gentoo

X
ce que la machine voit
 y
ce qu'elle doit deviner

fit

2. une règle
trouvée par la machine dans les exemples,
pas écrite par toi

predict
→ Gentoo

3. un manchot sans réponse

45	15	215	5000	?
----	----	-----	------	---

Des exemples avec la réponse, une règle trouvée par la machine, une réponse devinée pour du nouveau.

```

arbre.fit(X_train, y_train)      # apprendre
predictions = arbre.predict(X_test) # deviner

```

Cacher une partie des données


Si on te donne les réponses de l'examen la veille, ta note ne prouve rien. Un modèle se juge sur des données qu'il n'a jamais vues.

1. on coupe avant d'apprendre



le modèle voit X et y des 249 ; des 84 cachés, il ne voit que X, et on compare ses réponses au vrai y

2. l'exactitude sur les 84 cachés



On cache des données pour vérifier que le modèle a compris, et on compare toujours au modèle bête.


- EXACTITUDE, PAS PRÉCISION

L'exactitude, *accuracy* dans scikit-learn, est la part de bonnes réponses. En français courant on dirait « précision », mais en machine learning la précision est une autre mesure : parmi ce que le modèle a déclaré positif, la part qui l'est vraiment. Tu la retrouveras dans l'aide-mémoire scikit-learn du cours.

Pour deviner un nombre, bonne ou mauvaise réponse n'a plus de sens : on mesure de combien on se trompe en moyenne. La régression du poids des manchots se trompe de 296 g, le modèle bête qui répond toujours le poids moyen de 658 g.

Lire un arbre

Un arbre de décision pose des questions en cascade, comme au jeu « Qui est-ce ? ». Sur les 84 manchots cachés, il n'en rate que deux, des Chinstrap pris pour des Adélie.





Chaque case dit combien de manchots d'entraînement y arrivent. Une feuille pleine donne l'espèce majoritaire.

Un arbre pose des questions en cascade, et on peut le lire à voix haute.

Appris par cœur

Laisse l'arbre poser autant de questions qu'il veut : il finit par connaître chaque manchot d'entraînement, sans faire mieux sur les autres.



CE MODÈLE A-T-IL COMPRIS ? · SUR PAPIER

Pour chaque modèle, tranche : a-t-il compris, appris par cœur, ou ne fait-il pas mieux que le modèle bête ?

Il a compris : sur les cachés, il fait nettement mieux que le modèle bête, et presque aussi bien que sur les exemples

Il a appris par cœur : il est parfait ou presque sur les exemples, nettement moins bon sur les cachés : c'est le sur-apprentissage

Pas mieux que le modèle bête : sur les cachés, il ne fait pas mieux que le modèle bête, quel que soit son score

1. Arbre de profondeur 3, manchots : 96,8 % sur les exemples, 97,6 % sur les cachés ; le modèle bête fait 47,6 %.
2. k-NN avec un seul voisin, manchots : 100 % sur les exemples, 82,1 % sur les cachés.
3. Arbre de profondeur 3, Pokémon légendaires : 92,0 % sur les cachés ; « jamais légendaire » fait aussi 92,0 %.
4. Régression du poids : 316 g d'erreur moyenne sur les exemples, 296 g sur les cachés ; le modèle bête se trompe de 658 g.
5. Arbre de régression sans limite de profondeur : 0 g d'erreur sur les exemples, 325 g sur les cachés.
6. k-NN qui consulte les 249 manchots d'entraînement comme voisins : 47,6 % sur les cachés.

Les réponses sont dans le corrigé, en fin de leçon.

À toi : les Pokémon légendaires

La même recette sur les 800 Pokémon, en 15 minutes : prédire `Legendary` à partir des six stats.
Piège : il n'y a que 65 légendaires, et répondre « jamais légendaire » à tout le monde fait déjà 91,9 %.

La barre à battre : le modèle bête sur tes données de test, puis un arbre de profondeur 3 et son tableau croisé.

Compte les légendaires retrouvés, pas seulement l'exactitude : c'est là que les modèles se départagent.

Ta phrase, lue dans l'arbre : « mon modèle a compris que... ».

Entre deux séances

Le carnet `06_exercices.ipynb` : 12 exercices, de ★ à ★★★★★, avec vérification automatique, indices et solutions repliées. Il s'ouvre par un quiz de quatre questions, à se poser à voix haute au début de la séance suivante.

Mini-quiz

MINI-QUIZ • SUR PAPIER

Une seule bonne réponse par question.

1. Dans le tableau des manchots, quelle colonne est y ?
 - A. La longueur du bec
 - B. Le poids
 - C. L'espèce
 - D. Toutes les mesures ensemble

2. Un manchot a une nageoire de 215 mm et un bec épais de 15 mm. Que répond l'arbre ?
- A. Adélie
 - B. Chinstrap
 - C. Gentoo
 - D. L'arbre ne peut pas répondre
3. Le modèle répond juste sur 97,6 % des manchots cachés. Comment s'appelle ce pourcentage ?
- A. La précision
 - B. L'exactitude
 - C. L'erreur moyenne
 - D. Le rappel
4. Les k plus proches voisins passent de 85,7 % à 98,8 % quand on met les mesures à la même échelle. Pourquoi ?
- A. Le modèle a plus de données
 - B. Le poids, en milliers de grammes, écrasait les longueurs en millimètres dans le calcul des distances
 - C. On a changé la coupe train / test
 - D. k a changé

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Apprentissage supervisé, des exemples avec la réponse, la machine trouve la règle et l'applique à du nouveau.
2. X, ce que la machine voit ; y, ce qu'elle doit deviner ; fit apprend, predict devine.
3. On cache un quart des données pour vérifier, et on compare toujours au modèle bête.
4. L'exactitude est la part de bonnes réponses ; pour un nombre, on mesure l'erreur moyenne.
5. Parfait sur les exemples, moins bon sur les cachés, c'est le sur-apprentissage.

Corrigé

Ce modèle a-t-il compris ?

1. **Il a compris** · Presque le même score des deux côtés, et deux fois celui du modèle bête : la règle apprise vaut aussi pour des manchots jamais vus.
2. **Il a appris par cœur** · Avec un seul voisin, chaque manchot d'entraînement se reconnaît lui-même : 100 % garanti. Les 18 points perdus sur les cachés mesurent ce qu'il a retenu sans le comprendre.
3. **Pas mieux que le modèle bête** · 92 % a l'air excellent, mais répondre « non » à tout le monde fait pareil. Le tableau croisé le confirme : 3 légendaires retrouvés sur 16.
4. **Il a compris** · L'erreur est la même des deux côtés et deux fois plus petite que celle du modèle bête, qui répond toujours le poids moyen.
5. **Il a appris par cœur** · Zéro gramme d'erreur, c'est une feuille par manchot : l'arbre a recopié les exemples. Sur les cachés, il fait moins bien que la simple régression linéaire.
6. **Pas mieux que le modèle bête** · Avec tout le monde pour voisin, la majorité est toujours Adélie : il répond Adélie à chaque fois, exactement comme le modèle bête.

Mini-quiz

1. **C. L'espèce** · y, c'est ce que la machine doit deviner : l'espèce. Les quatre mesures forment X, ce qu'elle voit. Pour la régression du poids, les rôles changent : le poids devient y.
2. **C. Gentoo** · 215 mm, c'est plus que 206,5 : on part à droite. Puis 15 mm d'épaisseur, c'est moins que 17,55 : la feuille Gentoo, où tombent 89 manchots d'entraînement, tous Gentoo.
3. **B. L'exactitude** · La part de bonnes réponses s'appelle l'exactitude, accuracy en anglais. La précision existe aussi en machine learning, mais elle mesure autre chose ; l'erreur moyenne, elle, sert aux nombres.
4. **B. Le poids, en milliers de grammes, écrasait les longueurs en millimètres dans le calcul des distances** · k-NN compare des distances. Sans mise à l'échelle, 100 g d'écart pèsent autant que 100 mm, alors que les becs ne diffèrent que de quelques millimètres : le poids décidait presque seul.