

Kaggle Titanic 1/2

Le grand projet du parcours, en binôme : explorer les 891 passagers du Titanic, vérifier quatre hypothèses, créer des variables dont le titre extrait du nom, mesurer deux modèles par validation croisée et faire sa première soumission.

ON REPART AVEC · Une première soumission Kaggle et son score, noté dans le notebook.

01 UNE COMPÉTITION, TROIS FICHIERS 02 QUATRE HYPOTHÈSES
03 NETTOYER ET CRÉER DES VARIABLES 04 UNE RECETTE, CINQ CONTRÔLES
05 ENTRE DEUX SÉANCES

À LA FIN DE LA SÉANCE


Tu sauras vérifier une hypothèse avec un taux de survie et un graphique, avant de modéliser.

Tu sauras créer une variable, dont un titre extrait d'un texte avec une regex, et ranger la préparation dans une fonction.

Tu sauras mesurer un modèle par validation croisée et soumettre tes prédictions à une compétition.

Une compétition, trois fichiers

Le 15 avril 1912, le Titanic coule : 1 502 des 2 224 passagers et membres d'équipage meurent. Kaggle donne la fiche de 891 passagers et leur sort ; à toi de prédire celui de 418 autres.



La réponse des 418 passagers de test, Kaggle la garde : c'est ce qui rend le classement honnête.

Apprendre sur train, prédire test, soumettre deux colonnes, recevoir un score.

- AVANT LA SÉANCE : LES FICHIERS

Chacun crée un compte Kaggle gratuit, rejoint la compétition Titanic, qui ne demande pas d'accepter de règlement, et télécharge `train.csv` et `test.csv` ; le notebook détaille chaque étape. Dans

Colab, on les dépose dans le panneau des fichiers, et ils disparaissent quand la session se ferme. Sans eux, le notebook charge une copie publique de `train.csv` : tout fonctionne, sauf la soumission.

La page de la compétition [↗](#)

Quatre hypothèses

Un data scientist ne devine pas, il vérifie. Le trait pointillé marque la survie moyenne, 38,4 %.

HYPOTHÈSE 1 • CONFIRMÉE

Les femmes et les enfants d'abord

Sexe	Survie (%)
femmes	74
hommes	19

74 % des femmes survivent, 19 % des hommes.

HYPOTHÈSE 2 • CONFIRMÉE

La classe compte

Classe	Survie (%)
1re	63
2e	47
3e	24

63 % en 1re classe, 24 % en 3e.

HYPOTHÈSE 3 • CONFIRMÉE

Le prix du billet

Prix du billet	Survie (%)
bon marché	20
moyen	30
cher	45
très cher	58

près de 3 fois plus de survivants chez les plus chers.

HYPOTHÈSE 4 • NUANCÉE

La famille à bord

Famille à bord	Survie (%)
seul	20
2	55
3	58
4	72
5+	16

mieux à 2, 3 ou 4 ; seul ou à 5 et plus, c'est pire.

QUI A PLUS DE CHANCES ? • SUR PAPIER

Pour chaque duel, dis quel passager avait le plus de chances de survivre.

1. une femme de 3e classe ou un homme de 1re classe ?
2. un passager seul ou un passager d'une famille de 4 ?
3. un passager d'une famille de 6 ou un passager seul ?
4. un garçon au titre « Master » ou un homme au titre « Mr » ?
5. un passager embarqué à Southampton ou un passager embarqué à Cherbourg ?
6. un enfant de moins de 12 ans ou une femme ?

Les réponses sont dans le corrigé, en fin de leçon.

Nettoyer et créer des variables

177 âges manquent, soit un passager sur cinq. Plutôt que de remplir tous les trous avec le même âge, le nom du passager en dit plus qu'on ne croit.

1. le titre, entre la virgule et le point

Braund, Mr. Owen Harris

,\s*([^\.]+)\.

une virgule, des espaces éventuels,
puis tout ce qui n'est pas un point : on le garde

Mr

17 titres différents, dont beaucoup vus une fois
(Capt, Jonkheer...) : on les regroupe en cinq

2. ce que dit le titre

titre	passagers	survie	âge médian
Mr	517	16 %	30 ans
Miss	185	70 %	21 ans
Mrs	126	79 %	35 ans
Master	40	57 %	3,5 ans
Autre	23	35 %	48,5 ans

Pour les 177 âges manquants : l'âge médian du titre (3,5 ans pour un Master)
plutôt que 28 ans pour tout le monde, qui ferait un pic artificiel.

Le titre dit d'un coup le sexe, l'âge et le rang : l'une des variables les plus fortes du Titanic.

```
train["Titre"] = train["Name"].str.extract(r",\s*([^\.]+)\.")[0]
```

Une recette, cinq contrôles

Tout le nettoyage tient dans une fonction, `preparer()`, appliquée telle quelle à `train` puis à `test`.
Pour mesurer, on ne coupe plus une seule fois : on fait passer cinq contrôles.

1. cinq contrôles blancs sur les 891 passagers

contrôle					85,5 %
	contrôle				82,0 %
		contrôle			82,6 %
			contrôle		79,8 %
				contrôle	83,7 %

clair : les quatre paquets où la forêt apprend · plein : le paquet du contrôle

moyenne 82,7 %

2. la moyenne des cinq contrôles

modèle bête : personne ne survit

61,6 %

régression logistique

80,4 %

forêt, 200 arbres, profondeur 5

82,7 %

Cinq contrôles avec des sujets différents valent mieux qu'un seul.

- DEUX NOUVEAUX MODÈLES

La régression logistique est une cousine de la régression linéaire de la séance 6 : elle pèse chaque indice, puis bascule vers « survit » ou « ne survit pas ». La forêt aléatoire réunit 200 arbres de décision, chacun appris sur un échantillon un peu différent, qui votent. Sans limite de profondeur, la forêt tombe à 80,5 % : ses arbres apprennent par cœur, ce que la séance 8 reprend.

À toi : ta première soumission

En binôme, 10 minutes : l'un tape, l'autre réfléchit à voix haute.

Une variable de plus dans `preparer()` , par exemple le prix par personne, et la forêt remesurée.

Génère `submission.csv` avec la meilleure forêt, dépose-le sur la page de la compétition, et note le score dans le notebook.

Si le temps manque, la soumission ouvre la séance 8.

Entre deux séances

Le carnet `07_exercices.ipynb` : 12 exercices, de ★ à ★★★★★ , avec vérification automatique, indices et solutions repliées. Il s'ouvre par un quiz de deux questions, à se poser à voix haute au début de la séance suivante.

Mini-quiz

MINI-QUIZ · SUR PAPIER

Une seule bonne réponse par question.

1. Pourquoi ranger tout le nettoyage dans une seule fonction `preparer()` ?
 - A. Pour que le code soit plus court
 - B. Pour appliquer exactement la même recette à train et à test
 - C. Parce que Kaggle l'exige
 - D. Pour aller plus vite
2. Que garde la regex `,s*([^\.]*)\.` dans le nom « Heikkinen, Miss. Laina » ?
 - A. Heikkinen
 - B. Miss
 - C. Laina
 - D. Miss. Laina
3. Les cinq contrôles de la forêt donnent de 79,8 % à 85,5 %. Quel score annonces-tu ?
 - A. 85,5 %, le meilleur
 - B. 79,8 %, le pire
 - C. 82,7 %, la moyenne des cinq
 - D. Celui du premier contrôle

4. Pourquoi remplir les âges manquants avec l'âge médian du titre plutôt qu'avec 28 ans pour tout le monde ?

- A. Parce que 28 ans est faux
- B. Parce qu'un petit garçon au titre « Master » recevrait 28 ans, et 177 passagers formeraient un pic artificiel
- C. Parce que la médiane est interdite
- D. Pour avoir moins de lignes

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Sur Kaggle, train.csv sert à apprendre, test.csv à prédire, et le score est la part de passagers bien prédits.
2. On vérifie ses hypothèses avant de modéliser, chacune avec un chiffre.
3. Une nouvelle variable bien choisie, comme le titre, vaut souvent mieux qu'un modèle plus compliqué.
4. Une seule fonction préparer() pour train et test, sinon les deux fichiers ne se ressemblent plus.
5. La validation croisée fait passer cinq contrôles au modèle et garde la moyenne.

Corrigé

Qui a plus de chances ?

1. **une femme de 3e classe : 50 % de survie, contre 37 %** · Le sexe pèse plus lourd que la classe : même en 3e, une femme avait plus de chances qu'un homme de 1re.
2. **un passager d'une famille de 4 : 72 % de survie, contre 30 %** · Une petite famille a sans doute pu s'entraider. Mais attention, 29 passagers seulement : un petit groupe fait des taux fragiles.
3. **un passager seul : 30 % de survie, contre 14 %** · Au-delà de 4, la survie s'effondre. Ces grandes familles voyageaient surtout en 3e classe : 17 passagers sur 22 ici.
4. **un garçon au titre « Master » : 57 % de survie, contre 16 %** · « Master » désignait les petits garçons (âge médian 3,5 ans) : enfants d'abord. Le titre dit à la fois le sexe et l'âge.
5. **un passager embarqué à Cherbourg : 55 % de survie, contre 34 %** · Le port ne sauve personne : à Cherbourg, 85 passagers sur 168 étaient en 1re classe. C'est la classe qui se cache derrière le port.
6. **une femme : 74 % de survie, contre 57 %** · Les enfants s'en sortent mieux que la moyenne, mais les femmes plus encore : beaucoup d'enfants voyageaient en 3e classe.

Mini-quiz

1. **B. Pour appliquer exactement la même recette à train et à test** · Le modèle apprend sur des colonnes préparées d'une certaine façon ; test doit arriver exactement pareil. L'erreur classique : nettoyer train à la main et oublier une étape sur test.
2. **B. Miss** · Elle cherche une virgule, d'éventuels espaces, puis garde tout ce qui n'est pas un point, jusqu'au point : « Miss ». Les parenthèses marquent ce qu'on garde.
3. **C. 82,7 %, la moyenne des cinq** · Chaque contrôle dépend du paquet tiré ; la moyenne des cinq est plus fiable qu'un seul. Annoncer le meilleur, ce serait choisir le sujet d'examen qui t'arrange.
4. **B. Parce qu'un petit garçon au titre « Master » recevrait 28 ans, et 177 passagers formeraient un pic artificiel** · 28 ans est bien l'âge médian du bateau, mais pas celui de chacun. Le titre donne un âge plausible : 3,5 ans pour un Master, 35 pour une Mrs.