

Kaggle Titanic 2/2

Passer en mode compétition : comparer quatre modèles, comprendre pourquoi l'un gagne, voir le sur-apprentissage, régler deux boutons avec GridSearchCV, déjouer les pièges, puis soumettre et présenter sa démarche en cinq minutes.

ON REPART AVEC · Une soumission Kaggle finale avec son score, le notebook complet poussé sur GitHub, et une présentation de 5 minutes.

01 QUATRE MODÈLES, UN TABLEAU 02 POURQUOI L'UN GAGNE 03 APPRENDRE PAR CŒUR
04 RÉGLER LES BOUTONS 05 TROIS PIÈGES 06 PRÉSENTER EN CINQ MINUTES
07 ENTRE DEUX SÉANCES

À LA FIN DE LA SÉANCE


Tu sauras comparer des modèles avec la même validation croisée, en lisant l'écart-type autant que la moyenne.

Tu sauras expliquer une décision par l'importance des variables, et régler un modèle avec GridSearchCV.

Tu sauras reconnaître une fuite de données et un score trop beau pour être vrai.

Quatre modèles, un tableau

On reprend `preparer()` de la séance 7 et on mesure quatre familles de modèles avec la même validation croisée.



Le trait noir sur chaque barre : l'écart-type des cinq paquets. Un écart de 1 point entre deux modèles peut n'être que du hasard.

Quatre modèles dans un mouchoir de poche, et tous au-dessus de la règle bête.

- LE GRADIENT BOOSTING

Le gradient boosting construit de petits arbres l'un après l'autre, chacun corrigeant les erreurs du précédent : comme réviser en refaisant surtout les exercices ratés. La forêt, elle, fait voter des arbres construits chacun de son côté. Réglé par GridSearchCV, le boosting monte à 84,1 %.

Pourquoi l'un gagne




La forêt partage entre Titre et Sex, qui racontent la même histoire ; le boosting mise presque la moitié sur Titre.

Un score sans explication ne convainc personne : l'importance des variables dit sur quoi le modèle décide.

Retire Titre : la forêt passe de 82,7 à 82,0 % seulement, car Sex et Age portent presque la même information.

Apprendre par cœur

Comme l'élève qui connaît les annales par cœur et sèche devant un sujet nouveau.



Au-delà de la bonne profondeur, l'arbre gagne sur ce qu'il a vu et perd sur ce qu'il n'a pas vu.

Régler les boutons

		min_samples_leaf : passagers minimum par feuille			4 × 3 = 12 combinaisons × 5 paquets = 60 entraînements meilleur réglage : 82,9 % profondeur 5, feuilles d'au moins 3 tous entre 82,0 et 82,9 % : régler aide, mais moins qu'une bonne variable
		1	3	5	
max_depth	3	82,5 %	82,6 %	82,4 %	
	5	82,3 %	82,9 %	82,8 %	
	7	82,5 %	82,0 %	82,6 %	
	9	82,6 %	82,7 %	82,5 %	

Un hyperparamètre se choisit avant l'entraînement ; GridSearchCV essaie toutes les combinaisons d'une grille.

```
grille = {"max_depth": [3, 5, 7, 9], "min_samples_leaf": [1, 3, 5]}
foret = RandomForestClassifier(n_estimators=100, random_state=42)
recherche = GridSearchCV(foret, grille, cv=5).fit(X, y)
```

Trois pièges

Des scores magnifiques, et faux.

PIÈGE 1 • LA FUITE DE
DONNÉES

100,0 %

Une colonne Canot qui
recopie la survie : le modèle
triche sans le savoir.

Sur test.csv, la colonne n'existe
pas : le modèle est inutilisable.

PIÈGE 2 • SE NOTER SUR
SES DONNÉES

98,1 %

Une forêt sans limite, notée
sur les passagers qu'elle a
vus.

En validation croisée, la même
forêt fait 80,5 %.

PIÈGE 3 • OUBLIER LA
RÈGLE BÊTE

0,76555

« Toutes les femmes
survivent » : 320 bonnes
réponses sur 418 sur
Kaggle.

Un modèle qui ne bat pas ce
score ne sert à rien.

FUITE OU PAS FUITE ? • SUR PAPIER

Pour chaque colonne ajoutée, dis si elle fait fuiter la réponse.

Fuite : la colonne contient la réponse, ou n'existe qu'une fois la réponse connue : impossible de la calculer pour un passager de test.csv

Pas de fuite : l'information existait avant le naufrage, ou se calcule à partir de train seul, pour n'importe quel passager de test.csv

1. On ajoute une colonne Canot qui vaut 1 pour les passagers montés dans un canot.
2. On remplit les âges manquants de test.csv avec la médiane calculée sur train.
3. On ajoute le nombre de survivants parmi les passagers qui ont le même numéro de billet.
4. On ajoute le titre, Mr, Mrs, Miss, Master, extrait du nom.
5. On ajoute la taille de la famille à bord, SibSp + Parch + 1.
6. On ajoute le numéro d'identification des corps retrouvés après le naufrage.

Les réponses sont dans le corrigé, en fin de leçon.

- DES 1,00000 AU CLASSEMENT

Le classement de la compétition, calculé sur les 418 passagers de test, affiche des équipes à 1,00000. Personne ne prédit parfaitement un naufrage : la liste réelle des survivants est publique, et ces scores la recopient sans doute. Ce n'est pas du machine learning, et ça n'apprend rien.

À toi : la soumission finale

En binôme, 20 minutes, dans l'ordre :

Le modèle final : la forêt réglée par GridSearchCV ou le boosting, remesuré après une variable ajoutée ou retirée.

submission_finale.csv , soumis sur Kaggle, et tes deux scores notés : première soumission, finale.

Le tableau du groupe : chaque binôme annonce ses scores et son modèle.

Présenter en cinq minutes

Pas de diapositives obligatoires : le notebook et un ou deux graphiques suffisent.

PARTIE	DURÉE	CONTENU
Nos hypothèses	1 min	Les deux qui vous ont marqués, avec un chiffre chacune
Ce qu'on a essayé	2 min	Variables, modèles, le réglage qui a le plus compté, une chose qui n'a pas marché
Notre score	1 min	Première soumission, finale, et la place face à la règle bête
Ce qu'on referait	1 min	Avec deux heures de plus : quelle variable, quel modèle, quel piège éviter

Entre deux séances

Le carnet 08_exercices.ipynb : 12 exercices, de ★ à ★★★★★, avec vérification automatique, indices et solutions repliées. Il s'ouvre par une question, à se poser à voix haute au début de la séance suivante.

Mini-quiz

MINI-QUIZ • SUR PAPIER

Une seule bonne réponse par question.

1. L'arbre fait $82,3 \% \pm 2,2$, la régression logistique $80,4 \% \pm 0,7$. Lequel est le plus stable d'un paquet à l'autre ?
 - A. L'arbre, parce que sa moyenne est plus haute
 - B. La régression logistique, parce que son écart-type est plus petit
 - C. Les deux se valent
 - D. On ne peut pas savoir
2. Sans la variable Titre, la forêt passe seulement de $82,7 \%$ à $82,0 \%$. Pourquoi si peu ?
 - A. Titre ne servait à rien
 - B. Sex et Age portent presque la même information que Titre
 - C. La forêt a ignoré la consigne
 - D. Le score est faux
3. Lequel de ces réglages est un hyperparamètre ?
 - A. Le seuil « nageoire $\leq 206,5 \text{ mm}$ » trouvé par un arbre
 - B. max_depth, la profondeur maximale de l'arbre
 - C. Le score de validation croisée
 - D. La colonne Survived
4. Une grille de 4 profondeurs $\times$ 3 tailles de feuille, avec une validation croisée à 5 paquets : combien d'entraînements ?
 - A. 12
 - B. 15
 - C. 20
 - D. 60

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Même validation croisée pour tous les modèles, et un écart d'un point peut n'être que du hasard.

2. L'importance des variables dit sur quoi le modèle décide ; c'est l'argument à montrer.
3. Train qui monte, validation qui descend, c'est le sur-apprentissage.
4. Un hyperparamètre se règle avant l'entraînement ; GridSearchCV essaie toute une grille.
5. Un score trop beau est une alarme, fuite ou mesure sur ses propres données, et on bat toujours la règle bête d'abord.

Corrigé

Fuite ou pas fuite ?

1. **Fuite** · Être monté dans un canot, c'est presque avoir survécu. Le notebook le montre : avec la réponse déguisée, la forêt fait 100 %, et test.csv n'a pas cette colonne.
2. **Pas de fuite** · La médiane ne dépend que des passagers d'entraînement, et elle s'applique à n'importe qui. C'est même la bonne pratique : ne jamais regarder test pour préparer.
3. **Fuite** · Pour fabriquer cette colonne, il faut connaître Survived. Sur train le score s'envole ; sur test.csv, la colonne ne se calcule pas.
4. **Pas de fuite** · Le nom figure sur le billet, bien avant le naufrage, et test.csv le contient. C'est une variable créée, pas une réponse cachée.
5. **Pas de fuite** · Deux colonnes connues à l'embarquement, présentes dans les deux fichiers : aucune trace de la survie dans le calcul.
6. **Fuite** · Cette information n'existe que pour les victimes, donc seulement une fois la réponse connue. Un modèle qui s'en sert triche sans le savoir.

Mini-quiz

1. **B. La régression logistique, parce que son écart-type est plus petit** · L'écart-type mesure combien le score varie d'un paquet à l'autre. Celui de la logistique bouge de moins d'un point, celui de l'arbre de plus de deux : sa moyenne est plus haute, mais moins sûre.
2. **B. Sex et Age portent presque la même information que Titre** · Un titre dit le sexe et, pour Master ou Miss, l'âge. Quand on le retire, le modèle retrouve l'essentiel dans les colonnes Sex et Age : une variable importante n'est pas forcément irremplaçable.
3. **B. max_depth, la profondeur maximale de l'arbre** · Un hyperparamètre se choisit avant l'entraînement, comme la profondeur maximale. Les seuils des questions, eux, le modèle les apprend tout seul pendant fit.
4. **D. 60** · 12 combinaisons, et chacune est entraînée 5 fois, une par paquet : 60 entraînements. C'est pour ça qu'une grille trop grande devient vite lente.