

Comment fonctionne un LLM

Ouvrir le capot d'un modèle de langage : des tokens, un seul geste répété, deviner le mot suivant, la température qui règle le hasard, et un petit modèle qu'on fait halluciner exprès.

ON REPART AVEC · Un petit modèle qu'on a fait tourner et « halluciner » volontairement, et une fiche « 3 limites d'un LLM » observées soi-même.

01 DES TOKENS, PAS DES LETTRES 02 DEVINER LE MOT SUIVANT 03 LA TEMPÉRATURE
04 CE QU'IL NE SAIT PAS 05 PETIT MODÈLE, GROS MODÈLE 06 ENTRE DEUX SÉANCES

À LA FIN DE LA SÉANCE

- Tu sauras ce qu'est un token, et pourquoi un modèle compte mal les lettres.
- Tu sauras expliquer « prédire le mot suivant » et ce que change la température.
- Tu sauras reconnaître une hallucination, une date de connaissance dépassée et un calcul faux.

Des tokens, pas des lettres

Un ordinateur ne lit que des nombres. Avant de lire ta phrase, le modèle la découpe en tokens, et chaque token a un numéro. Tout ce qui suit sort du modèle du notebook, Qwen 2.5 0.5B, lancé pour de vrai.

1. ce que lit le modèle : 17 tokens, pas des lettres

Les	man	ch	ots	de	l	'	Ant	ar	ct	ique	adore	nt	le	machine	learning	.
23711	883	331	2412	409	326	6	17117	277	302	2372	60635	406	512	5662	6832	13

␣ marque l'espace collé au début du token ; sous chaque morceau, le numéro que le modèle reçoit vraiment

2. le même message, deux langues

français		15 tokens
anglais		12 tokens

« J'adore jouer aux jeux vidéo avec mes amis le week-end. »
« I love playing video games with my friends on the weekend. »

3. pourquoi il compte mal les lettres

str	aw	berry
-----	----	-------

« strawberry », pour le modèle : trois numéros, aucune lettre isolée à compter


Un modèle lit des morceaux de mots numérotés ; le français en demande plus que l'anglais.

Deviner le mot suivant

Un modèle de langage ne fait qu'une chose : lire ce qui précède et deviner le token suivant, puis recommencer. Le notebook construit d'abord le plus petit modèle possible, un bigramme.


le bigramme : après « le », il a vu...

36 phrases, un comptage par couple de mots



le vrai modèle : après « Le chat dort sur le »...

probabilité de chaque token suivant, sur > 150 000 possibles



« ␣p », « ␣to » : des débuts de mots ; le mot se finit au token d'après

Le bigramme compte après un seul mot ; le vrai modèle calcule une probabilité après toute la phrase.


- POURQUOI LE BIGRAMME TOURNE EN ROND

Parti de « le », le bigramme choisit toujours le mot le plus fréquent : « chat », puis « dort », puis « dans », puis de nouveau « le ». Il écrit « le chat dort dans le chat dort dans le chat... » sans fin. Un vrai modèle regarde des milliers de tokens précédents, pas un seul, et il a lu des milliards de phrases, pas 36.

La température

Les vrais modèles tirent au sort parmi les tokens probables. La température règle ce hasard.

même phrase, trois températures



le pourcentage : la part du premier token, « ␣p », à chaque température ; softmax(logits ÷ T)

« un nom original pour un chat »

température 0

"Kitty"
"Kitty"
"Kitty"

température 1,5

Papillon
"ChatGym"
Chatbot

vrai modèle, graines 0, 1, 2

La température règle le hasard : basse, toujours la même réponse ; haute, des choix de plus en plus égaux.

Ce qu'il ne sait pas

Le modèle écrit le plus plausible, pas le vrai. Posées au vrai modèle, quatre questions précises :

LA QUESTION Qui a gagné la Coupe du monde de football 2031 ? LE MODÈLE RÉPOND La France a gagné la Coupe du Monde de football 2031 en remportant le titre. La vérité. Cette Coupe du monde n'a pas encore eu lieu.	LA QUESTION Combien font $4\,817 \times 2\,953$? Réponds juste le nombre. LE MODÈLE RÉPOND 24,605,311 La vérité. Python : 14 224 601	LA QUESTION Combien de lettres r dans le mot strawberry ? LE MODÈLE RÉPOND Le mot "strawberry" contient 4 lettres r. La vérité. Python : 3	LA QUESTION Qui est le maire de Trifouillis-les-Oies ? LE MODÈLE RÉPOND Le maire de Trifouillis-les-Oies est Jean-Pierre Rousset. La vérité. Ce village n'existe pas.
---	---	---	--

QUELLE LIMITE ? • SUR PAPIER

Pour chaque réponse du modèle, nomme la limite qui explique l'erreur.

Hallucination : il invente, sûr de lui, un fait sur quelque chose qui n'existe pas ou n'a pas encore eu lieu

Date de connaissance : il répond sur l'actualité avec des informations arrêtées à ses données d'entraînement

Calcul : il donne un résultat de calcul faux : il écrit des chiffres plausibles au lieu de poser l'opération

Lettres et tokens : il se trompe sur des lettres, parce qu'il voit des morceaux de mots, pas des lettres

1. « Qui a gagné Roland-Garros en 2034 ? » · réponse du modèle : « L'équipe de France a gagné Roland-Garros en 2034. »

2. « Résume en 2 phrases la carrière du chanteur Théo Bilborne. » · réponse du modèle : « Théo Bilborne a remporté le concours de rap "Rap de l'année" et est sorti avec "Bilborne". »

3. « Quel est le dernier iPhone sorti, et en quelle année sommes-nous ? » · réponse du modèle : « Le dernier iPhone a été sorti en 2019. Nous sommes actuellement en 2023. »

4. « Quel est le dernier jeu sorti sur Nintendo Switch ? » · réponse du modèle : « Le dernier jeu sorti sur Nintendo Switch était "Super Mario Odyssey". »

5. « Combien font $7\,391 \times 6\,128$? Réponds juste le nombre. » · réponse du modèle : « 40,596,320 »

6. « Combien de lettres e dans le mot anticonstitutionnellement ? » · réponse du modèle : « 7 »


Les réponses sont dans le corrigé, en fin de leçon.

- ET LA CONSIGNE « SI TU N'ES PAS SÛR, DIS JE NE SAIS PAS » ?

Ajoutée au prompt système, elle n'a pas suffi au petit modèle : il a inventé un autre maire, avec une date d'élection. Plus le modèle est petit, moins il suit les consignes.

Petit modèle, gros modèle

Le modèle du cours tourne dans Colab gratuit, et même sur un ordinateur portable. Un gros modèle tourne sur les serveurs de son éditeur : il faut du réseau, et tes messages partent là-bas.



Un paramètre est un nombre réglé pendant l'entraînement ; le petit modèle du cours en a un demi-milliard.

- LE SAC DE MOTS, AVANT LES LLM

Avant les LLM, un filtre anti-spam comptait les mots d'un message : « gagné », « gratuit », « cliquez » sentent le spam. Le notebook refait cette méthode sur 20 messages, puis la piège. Résultat du vrai passage : le sac de mots laisse passer le faux message de la banque, faute d'en connaître les mots, et le petit modèle répond « spam » à tout, même à « On se voit demain au foot ? ». À cette taille, il suit mal la consigne.

À toi : fais halluciner le modèle

Tu deviens testeur de LLM, 20 minutes.

Cinq pièges, un par catégorie : un événement futur, une personne inventée, un calcul, l'actualité, des lettres à compter.

Note la réponse et la vérité, vérifiée avec Python ou une source fiable. Une bonne réponse est aussi une observation.

Ta fiche « 3 limites », chacune avec son explication et ton meilleur piège.

Entre deux séances

Le carnet 09_exercices.ipynb : 12 exercices, de ★ à ★★★★★, avec vérification automatique, indices et solutions repliées. Il s'ouvre par un quiz de deux questions, à se poser à voix haute au début de la séance suivante.

Mini-quiz

MINI-QUIZ • SUR PAPIER

Une seule bonne réponse par question.

1. La même idée coûte 15 tokens en français et 12 en anglais. Pourquoi ?
 - A. Le français a plus de lettres
 - B. Le découpage a été construit sur beaucoup plus de texte anglais : ses gros morceaux sont surtout des mots anglais
 - C. Les accents comptent double
 - D. C'est un hasard
2. Parti de « le », le bigramme écrit « le chat dort dans le chat dort dans le chat... ». Pourquoi tourne-t-il en rond ?
 - A. Il manque des phrases
 - B. Il choisit toujours le mot le plus fréquent après le mot d'avant, et « dans » ramène toujours à « le »
 - C. Le mot « chat » est interdit
 - D. Il a trop de paramètres
3. Trois fois la même question à température 0 : que se passe-t-il ?
 - A. Trois réponses différentes
 - B. Trois fois la même réponse, le token le plus probable à chaque étape
 - C. Le modèle refuse de répondre
 - D. La réponse est plus juste
4. Avec le petit modèle du cours, dans Colab, où partent tes messages ?
 - A. Sur les serveurs d'une grande entreprise
 - B. Nulle part : le modèle tourne dans ta session, tes données restent là
 - C. Chez Hugging Face à chaque question
 - D. Sur ton compte Google Drive

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Un modèle lit des tokens, des morceaux de mots numérotés, pas des lettres.
2. Un LLM ne fait qu'une chose, prédire le token suivant, encore et encore.
3. La température règle le hasard, basse pour la même réponse, haute pour la variété puis le n'importe quoi.
4. Il écrit le plausible, pas le vrai ; plus la question est précise, plus il faut vérifier.
5. Petit modèle, gratuit et chez toi ; gros modèle, dans le cloud, meilleur et payant.

Corrigé

Quelle limite ?

1. **Hallucination** · 2034 n'a pas encore eu lieu, et aucune équipe nationale ne gagne Roland-Garros. Le modèle écrit la suite la plus plausible, pas la vraie.
2. **Hallucination** · Ce chanteur n'existe pas. Plutôt que « je ne sais pas », le modèle fabrique une carrière crédible.
3. **Date de connaissance** · Il ne sait pas quel jour on est : il répond avec ce qu'il a lu pendant son entraînement, déjà ancien.
4. **Date de connaissance** · Un jeu réel, mais pas le dernier : ses données s'arrêtent avant aujourd'hui, et il ne le dit pas.
5. **Calcul** · Python donne 45 292 048. Le modèle écrit un nombre qui a l'air juste, chiffre après chiffre, sans poser l'opération.
6. **Lettres et tokens** · Python compte 3 e. Le modèle voit ant, icon, stitution, nel, lement : des morceaux, pas des lettres.

Mini-quiz

1. **B. Le découpage a été construit sur beaucoup plus de texte anglais : ses gros morceaux sont surtout des mots anglais** · Un tokenizer garde en un seul morceau les suites de lettres qu'il a le plus vues. Un mot français est plus souvent coupé en deux ou trois : la même phrase coûte plus de tokens, donc plus de calcul.
2. **B. Il choisit toujours le mot le plus fréquent après le mot d'avant, et « dans » ramène toujours à « le »** · Un bigramme ne regarde qu'un mot en arrière. Toujours prendre le plus fréquent l'enferme dans une boucle ; tirer au sort parmi les mots probables, c'est ce que règle la température.
3. **B. Trois fois la même réponse, le token le plus probable à chaque étape** · À température 0, il n'y a plus de tirage : le vrai modèle a répondu « Kitty » les trois fois. Plus haut, les réponses varient, parfois jusqu'à l'absurde.
4. **B. Nulle part : le modèle tourne dans ta session, tes données restent là** · Le notebook télécharge le modèle une fois, puis tout se calcule dans ta session Colab. Avec l'API d'un gros modèle, au contraire, chaque message part sur le serveur de son éditeur.