

Le RAG

Donner de la mémoire à son IA : un modèle ne connaît pas tes documents, alors on cherche les bons passages et on les glisse dans le prompt. Découper, vectoriser, chercher, injecter, répondre.

ON REPART AVEC · Un assistant RAG qui répond à des questions sur des documents choisis par soi.

01 LE MODÈLE NE CONNAÎT PAS TES DOCUMENTS 02 DES SENS PROCHES, DES POINTS PROCHES
03 CINQ ÉTAPES 04 QUAND IL SE TROMPE 05 ENTRE DEUX SÉANCES

À LA FIN DE LA SÉANCE

Tu sauras dire pourquoi un modèle invente sur tes documents, et comment le RAG l'en empêche.

Tu sauras ce qu'est un embedding et lire une similarité cosinus.

Tu sauras construire les cinq étapes d'un RAG et dire, quand il se trompe, si c'est la recherche ou la réponse.

Le modèle ne connaît pas tes documents

Le notebook invente un jeu de cartes, Sardine Express, et écrit ses règles : aucun modèle ne les a jamais lues. La même question, posée trois fois au vrai modèle du notebook :

SANS RIEN

le modèle ne connaît pas ce jeu

LE MODÈLE RÉPOND

Si on pose une carte Mouette dans Sardine Express, c'est qu'on a trouvé une carte d'argent et il est temps de commencer à jouer la partie !

INVENTÉ

TOUTES LES RÈGLES DANS LE PROMPT

15 paragraphes collés d'un bloc

LE MODÈLE RÉPOND

Si un joueur pose une carte Mouette, le joueur suivant doit alors poser 2 cartes et passer son tour.

PRESQUE : « POSER » AU LIEU DE « PIOCHER »

AVEC LE RAG

les 3 paragraphes les plus proches

LE MODÈLE RÉPOND

Quand on pose une carte Mouette, le joueur suivant doit piocher 2 cartes et passer son tour.


JUSTE

- POURQUOI NE PAS TOUJOURS COLLER TOUT LE TEXTE ?

Quinze paragraphes tiennent dans un prompt, un livre de 300 pages non : chaque token se paie en calcul ou en argent, et un petit modèle se perd dans trop de texte. Ici, même avec les règles sous les yeux, il a écrit « poser » au lieu de « piocher ». Le RAG ne donne que les passages utiles.

Des sens proches, des points proches

Pour trouver la bonne page, il faut mesurer si deux textes parlent de la même chose.



similarité cosinus

l'angle entre deux flèches : 1 = même direction, 0 = rien à voir


chat · chien	0,98
pomme · banane	0,99
chat · camion	0,24

Ici, deux nombres par mot, écrits à la main.

Le modèle d'embeddings du RAG en calcule 384 par paragraphe : impossible à dessiner, même calcul de cosinus.

Un embedding fait d'un texte une liste de nombres ; des sens proches donnent des points proches.

Cinq étapes



« Que se passe-t-il quand on pose une carte Mouette ? »

les trois paragraphes trouvés, et leur score :

- ¶6 0,616 La carte Mouette peut être posée sur n'importe quelle...
- ¶3 0,510 Au début de la partie, on mélange toutes les cartes. Chaque...
- ¶9 0,510 Le premier joueur qui n'a plus de cartes gagne la manche...

le modèle répond : Quand on pose une carte Mouette, le joueur suivant doit piocher 2 cartes et passer son tour.

Un RAG cherche la bonne page, la glisse dans le prompt, puis laisse le modèle répondre.

Le notebook a deux façons de vectoriser. Les embeddings cherchent par sens : « la carte qui fait piocher deux cartes » et « la carte Mouette » sont à 0,609, contre 0,145 pour « le jeu a été créé en 2019 ». Le repli TF-IDF compte les mots en commun, comme un Ctrl+F. Parfois, il gagne : pour « Qui a créé le jeu ? », c'est lui qui trouve le bon paragraphe.

Quand il se trompe

Un RAG peut rater à deux endroits : la recherche ne trouve pas la bonne page, ou le modèle l'a sous les yeux et répond autre chose. Voici six vraies questions, leurs passages trouvés et la vraie réponse.

OÙ LE RAG A-T-IL RATÉ ? · SUR PAPIER

Pour chaque question, regarde les passages trouvés et la réponse, puis dis où ça a raté.


La recherche : la réponse est dans les règles, mais aucun des passages trouvés ne la contient

La réponse : un des passages trouvés contient la réponse, mais le modèle en écrit une autre

Rien, c'est juste : la réponse est juste, et elle vient des passages trouvés

1. « Qui a créé le jeu ? » · passages trouvés : n° 7 (0,485), n° 4 (0,427), n° 3 (0,411) · réponse : « Le jeu Tempête est un jeu de société créé par l'artiste et designer de jeux David K. Sperber. »
2. « Qui a illustré le jeu ? » · passages trouvés : n° 7 (0,527), n° 4 (0,46), n° 3 (0,433) · réponse : « Le jeu a été illustré par l'artiste français Jean-François Millet. »
3. « Que se passe-t-il si on oublie de crier Sardine ? » · passages trouvés : n° 8 (0,46), n° 5 (0,357), n° 1 (0,335) · réponse : « Si un joueur ose crier Sardine sans avoir déjà fait cela lors de sa première ronde, il devra alors se rappeler et se remettre en question. »
4. « Que se passe-t-il quand on fait 6 au dé après une Tempête ? » · passages trouvés : n° 7 (0,45), n° 13 (0,262), n° 3 (0,19) · réponse : « Si on fait 6 au dé après avoir lancé un dé avec le sens inverse de la tempête, chaque joueur perd une carte, sauf celui qui était dans son poing droit. »
5. « Que fait-on quand la pioche est vide ? » · passages trouvés : n° 13 (0,589), n° 3 (0,314), n° 7 (0,293) · réponse : « On mélange la défausse (sauf la carte du dessus) pour former une nouvelle pioche. »
6. « Que risque un joueur qui triche ? » · passages trouvés : n° 8 (0,636), n° 14 (0,631), n° 9 (0,569) · réponse : « Il risque de perdre la manche en cours. »

Les réponses sont dans le corrigé, en fin de leçon.



Hors sujet, les scores restent bas : un seuil refuse la question avant même d'appeler le modèle.

À toi : pose une question à ton cours

Tes notes, les règles d'un jeu, le résumé d'un livre : 25 minutes pour ton assistant.

Colle ton texte, au moins huit paragraphes séparés par une ligne vide, puis découpe et vectorise.

Pose cinq questions, dont une hors sujet, et note si chaque réponse est juste.

Quand il se trompe, affiche les passages trouvés : recherche ou réponse ? Puis règle la taille des chunks, `k` ou la consigne.

Entre deux séances

Le carnet `11_exercices.ipynb` : 12 exercices, de ★ à ★★★★★, avec vérification automatique, indices et solutions repliées. Il s'ouvre par une question, à se poser à voix haute au début de la séance suivante.

Mini-quiz

MINI-QUIZ · SUR PAPIER

Une seule bonne réponse par question.

1. Dans le dessin à deux axes, chat et camion ont une similarité cosinus de 0,24. Ça veut dire quoi ?
 - A. Ils sont presque identiques
 - B. Leurs flèches partent dans des directions très différentes : ils ne parlent pas de la même chose
 - C. Le camion est plus gros
 - D. Il y a une erreur de calcul

2. Pourquoi ne pas coller tout un livre de 300 pages dans le prompt, au lieu de chercher des passages ?
 - A. Le modèle refuse les livres
 - B. Chaque token se paie, et un petit modèle se perd dans trop de texte
 - C. Les livres sont protégés
 - D. Le prompt système ne prend que des questions
3. « La carte qui fait piocher deux cartes » et « la carte Mouette » sont à 0,609 avec les embeddings. Pourquoi si proches ?
 - A. Elles ont beaucoup de mots en commun
 - B. Le modèle d'embeddings rapproche les textes par leur sens, pas seulement par leurs mots
 - C. Le mot « carte » compte double
 - D. Par hasard
4. « Quelle est la capitale du Japon ? » obtient un meilleur score de 0,105, sous le seuil de 0,3. Que fait l'assistant ?
 - A. Il envoie quand même les passages au modèle
 - B. Il répond « rien trouvé dans les documents » sans appeler le modèle
 - C. Il cherche sur internet
 - D. Il baisse le seuil

Les réponses sont dans le corrigé, en fin de leçon.

À retenir

1. Un modèle ne connaît pas tes documents ; si on ne lui donne rien, il invente.
2. Le RAG est un examen à livre ouvert, on cherche la bonne page et on la glisse dans le prompt.
3. Un embedding fait d'un texte une liste de nombres ; des sens proches donnent des points proches.
4. Cinq étapes, découper, vectoriser, chercher, injecter, répondre.
5. Quand un RAG se trompe, on regarde d'abord les passages trouvés, puis la réponse.

Corrigé

Où le RAG a-t-il raté ?

1. **La recherche** · La réponse est au paragraphe 15 : Léa Marchand, en 2019. Aucun des trois passages trouvés ne la contient, et le modèle invente un auteur.
2. **La recherche** · Le paragraphe 15 dit Tom Ravel, mais la recherche ramène la Tempête et le premier joueur. Sans la bonne page, le modèle en fabrique une.
3. **La réponse** · Le premier passage est le bon : trois cartes de pénalité. Le modèle l'avait sous les yeux et a écrit autre chose.
4. **La réponse** · Le paragraphe 7 est trouvé en premier : sur un 6, chacun passe sa main à son voisin de gauche. La réponse invente une perte de carte.
5. **Rien, c'est juste** · Le bon paragraphe arrive en tête, nettement, et la réponse le reprend presque mot pour mot.
6. **Rien, c'est juste** · Le paragraphe 14 est parmi les trois passages, et la réponse dit ce qu'il dit : perdre la manche en cours.

Mini-quiz

1. **B. Leurs flèches partent dans des directions très différentes : ils ne parlent pas de la même chose** · La similarité cosinus regarde l'angle entre deux vecteurs : 1, même direction ; proche de 0, rien à voir. Chat et chien, eux, sont à 0,98.
2. **B. Chaque token se paie, et un petit modèle se perd dans trop de texte** · Plus le prompt est long, plus il coûte, en temps ou en argent, et plus le modèle se disperse. Le RAG n'envoie que les quelques passages qui servent.
3. **B. Le modèle d'embeddings rapproche les textes par leur sens, pas seulement par leurs mots** · Seul « carte » est commun aux deux phrases. Le modèle d'embeddings a appris que des phrases de sens voisin donnent des vecteurs voisins ; TF-IDF, lui, ne voit que les mots.
4. **B. Il répond « rien trouvé dans les documents » sans appeler le modèle** · Sous le seuil, aucun passage ne parle vraiment de la question. Refuser avant d'appeler le modèle évite une réponse inventée et économise des tokens.